

CNN

注：该卷积和数学的卷积有区别实际

上是数学的互相关，不翻转被卷积

数学：

$$S(i,j) = (X * W)(i,j) = \sum_m \sum_n X(i+m, j+n) W(m,n)$$

会翻转和后再相乘求和

实际 CNN：

$$S(i,j) = (X * W)(i,j) = \sum_m \sum_n X(i+m, j+n) W(m,n)$$

若输入是多维的时候，卷积也是多维，相乘求和再对最后一维求和。

一般使用 $\text{ReLU}(x) = \max(0, x)$

池化 $\begin{cases} \max \\ \text{average} \end{cases}$

前向传播：

$$a^2 = \sigma(z^2) = \sigma(a^1 * W^2 + b^2)$$

1. 卷积核一般不止 1, k, 那么下层的输入就是 k 了

2. Padding：更好识别边缘

反向传播：

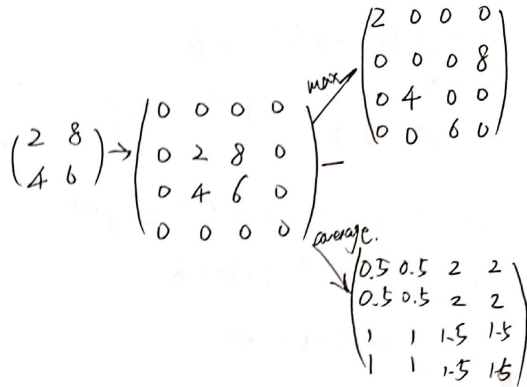
1. 已知池化层在 δ^L ，推导上层 δ^{L+1}

前向传播过程中，用 max, average 池化了
采用 upsample 把采样后的误差还原

~~max~~：先把 δ^L 的所有子矩阵矩阵大小还原成池化之前的大小。

① max：把 δ^L 所有子矩阵的各 1 池化后域的值放在之前做前向传播时最大值的位置

② average：把 δ^L 所有子矩阵各 1 池化后域的值取平均后放在还原后的子矩阵位置。



$$\delta^{L+1} = \left(\frac{\partial a_k^L}{\partial z_k^L} \right)^T \frac{\partial J}{\partial a_k^L} = \text{upsample}(\delta_k^L) \odot \sigma'(z_k^L)$$

upsample 是成池化误差矩阵放大与误差重新分配

2. 已知卷积层在 δ^L ，推导上层 δ^{L+1}

$$\delta^{L+1} = \left(\frac{\partial z^{L+1}}{\partial z^L} \right) \delta^L$$

$$z^L = a^{L+1} * W^L + b^L = \sigma(z^L) * W^L + b^L$$

$$\delta^{L+1} = \left(\frac{\partial z^{L+1}}{\partial z^L} \right)^T \delta^L = \delta^L \text{rot180}(W^L) \odot \sigma'(z^L)$$

卷积核被旋转了 180°，上下翻转，左右翻转

已知卷积层在 δ^L ，推导该层的 W, b 梯度。

池化层无 W, b

卷积层有 W, b ， $z^L = a^{L+1} * W + b$

$$\frac{\partial J}{\partial W^L} = a^{L+1} * \delta^L \quad \text{卷积核没有反转，层内求导}$$

$$\frac{\partial J}{\partial b^L} = \sum_{k,v} (\delta^L)_{k,v}$$

1. 局部连接, 权重共享, 汇聚
 ① 参数太多 } 全连接解决不了
 ② 局部不变性

2. 导数: $Y = W \otimes X$, $X \in R^{M \times N}$, $W \in R^{m \times n}$
 $Y \in R^{(M-m+1) \times (N-n+1)}$ $f(Y) \in R$

$$y_{ij} = \sum_{u,v} w_{uv} x_{i+u-1, j+v-1}$$

$$\frac{\partial f(Y)}{\partial w_{uv}} = \sum_{i=1}^{M-m+1} \sum_{j=1}^{N-n+1} \frac{\partial y_{ij}}{\partial w_{uv}} \frac{\partial f(Y)}{\partial y_{ij}}$$

$$= \sum_{i=1}^{M-m+1} \sum_{j=1}^{N-n+1} x_{i+u-1, j+v-1} \frac{\partial f(Y)}{\partial y_{ij}}$$

$$= \sum_{i=1}^{M-m+1} \sum_{j=1}^{N-n+1} \frac{\partial f(Y)}{\partial y_{ij}} x_{i+u-1, j+v-1}$$

$$\frac{\partial f(Y)}{\partial W} = \frac{\partial f(Y)}{\partial Y} \otimes X$$

网络: $\frac{\partial f(Y)}{\partial x_{st}} = \sum_{i=1}^{M-m+1} \sum_{j=1}^{N-n+1} \frac{\partial y_{ij}}{\partial x_{st}} \frac{\partial f(Y)}{\partial y_{ij}}$

$$= \sum_{i=1}^{M-m+1} \sum_{j=1}^{N-n+1} w_{s-i+1, t-j+1} \frac{\partial f(Y)}{\partial y_{ij}}$$

$$\therefore \frac{\partial f(Y)}{\partial X} = \text{rot180}\left(\frac{\partial f(Y)}{\partial Y}\right) \otimes W$$

CNN:

1) $z^{(1)}$: 第1层输入

$a^{(1)}$: 第1层激活层

$w^{(1)} \in R^m$: filter

$$z^{(1)} = w^{(1)} \otimes a^{(1)} + b^{(1)}$$

① 局部连接: $n^{(1)} \times n^{(1+1)} \rightarrow n^{(1)} \times m$

② 权重共享: $m+1$ 参数与神经元的数
 关, $n^{(1)} = n^{(1+1)} + m + 1$

$$z^p = W^p \otimes X + b^p$$

$$= \sum_{d=1}^p W^{p,d} \otimes X^d + b^p$$

$$Y^p = f(z^p) \quad f(\cdot) = \text{ReLu}(\cdot)$$

共 $p \times D \times (m \times n) + p$ 参数

③ 汇聚层

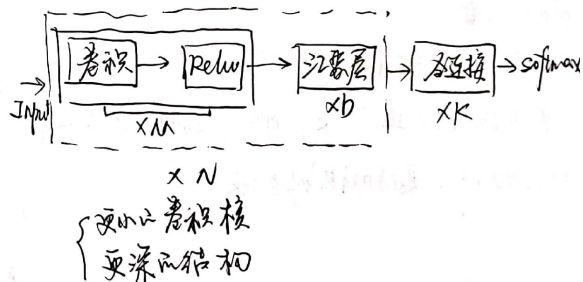
$\begin{cases} \text{max-pooling} \\ \text{mean-pooling} \end{cases}$

④ 减小神经元的数量

⑤ 减小局部连接保持不变性, 并拥有更大的感受野

★

特殊的卷积层, 核函数是 max 或 mean



2) 残差网络

$$h_m = x + (h_m - x)$$

$$= x + f(\theta, x)$$

4) Inception 网络:

常用卷积.


① 窄卷积: 步长 $s=1$, 两端不补 0,
输出长 $n-m+1$

② 宽卷积: 步长 $s=1$, 两端补 $p=m-1$
输出长 $n+m-1$

③ 等宽卷积: 步长 $s=1$, 两端补 $p=\frac{m-1}{2}$
输出长度 n

Inception

同时使用 $1 \times 1, 3 \times 3, 5 \times 5$ 不同大小的
卷积核, 得到的特征映射在深度上
堆叠起来



1×1 卷积用来减少特征映射深度, 如果
存在冗余信息, 1×1 卷积先进行一次特
征抽取.