

## 第6章 支持向量机

### 6.1 间隔与支持向量

划分超平面:  $w^T x + b = 0$  ( $w, b$ )

$w = (w_1, w_2, \dots, w_d)$  法向量, 决定超平面的方向

$b$ : 位移项, 决定超平面与原点的距离

样本空间点  $x$  到 ( $w, b$ ) 的距离:


$$r = \frac{|w^T x + b|}{\|w\|}$$

正确分类:  $\begin{cases} y_i \geq +1, & w^T x + b > 0 \\ y_i = -1, & w^T x + b < 0 \end{cases}$

$$\text{令 } \begin{cases} w^T x_i + b \geq +1, & y_i = +1 \\ w^T x_i + b \leq -1, & y_i = -1 \end{cases}$$

使上述等号成立的点  $(x_i, y_i)$  称为“支持向量”

两异类支持向量到超平面的距离之和



找到“最大间隔”的划分超平面

$$\max_{w, b} \frac{2}{\|w\|}$$

$$\text{s.t. } y_i(w^T x_i + b) \geq 1 \quad i=1, 2, \dots, m$$

$$\text{最大化 } \frac{2}{\|w\|} \Leftrightarrow \text{最大化 } \frac{1}{\|w\|^2}$$

即: 变为

$$\max_{w, b} \frac{1}{\|w\|^2}$$

$$\text{s.t. } y_i(w^T x_i + b) \geq 1 \quad i=1, 2, \dots, m$$

凸二次规划, 参数为  $w, b$

6.2 对偶问题  $\begin{cases} \text{① 更新原始解} \\ \text{② 自然引入核函数} \end{cases}$  ★

使用拉格朗日乘子法:

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i [1 - y_i (w^T x_i + b)] \quad \text{①}$$

其中  $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_m)$

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^m \alpha_i y_i x_i = 0 \Rightarrow w = \sum_{i=1}^m \alpha_i y_i x_i \quad \text{②}$$

$$\frac{\partial L}{\partial b} = - \sum_{i=1}^m \alpha_i y_i = 0 \quad \text{③}$$

④ 代入①式:

$$\begin{aligned} L(w, b, \alpha) &= \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \\ &\quad - \sum_{i=1}^m \alpha_i y_i \left( \left( \sum_{j=1}^m \alpha_j y_j x_j \right) \cdot x_i + b \right) + \sum_{i=1}^m \alpha_i \\ &= \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^m \alpha_i \\ &\text{s.t. } \sum_{i=1}^m \alpha_i y_i = 0 \\ &\quad \alpha_i \geq 0 \quad i=1, 2, \dots, m \end{aligned}$$

解出  $\alpha$  后, 即得  $w, b$

$$\begin{cases} w = \sum_{i=1}^m \alpha_i y_i x_i \\ b = y_i - \sum_{j=1}^m \alpha_j y_j (x_i \cdot x_j) \end{cases} \quad \begin{matrix} \alpha_j > 0 \\ \text{对 } \lambda_m(x_i, y_i) \end{matrix}$$

$\alpha_i$  是拉格朗日乘子, 对应  $(x_i, y_i)$

即为③式不等式:

即: 满足 KKT 条件

$$\begin{cases} \alpha_i \geq 0 \\ y_i f(x_i) + 1 \geq 0 \\ \alpha_i (y_i f(x_i) + 1) = 0 \end{cases}$$

对任意样本  $(x_i, y_i)$ ,  $\alpha_i = 0$  或  $y_i f(x_i) = 1$

① 若  $\alpha_i = 0$  则不会在  $w$  的求和中出现

② 若  $\alpha_i > 0$  则  $y_i f(x_i) = 1$ , 位于最大间隔边界上, 即支持向量

SVM 算法: 固定  $\alpha$  之外参数, 求  $\alpha$  上的极值

∴  $\sum_{i=1}^m \alpha_i y_i = 0$ , 固定  $\alpha$  之外参数,  $\alpha_i$  由其他

导出, 每个这样两变量, 固定其他参数。

SMD:

① 选取对  $\alpha_i, \alpha_j$

② 固定  $\alpha_i, \alpha_j$  以外参数, 求得更新值  
in  $\alpha_i, \alpha_j$

至违背 KKT 条件程度最大变量  $\alpha_i$

后选两变量对为样本间隔最大  $\alpha_j$

### 6.3 核函数

原始空间  $\xrightarrow{\text{映射}}$  更高维特征空间  
(线性不可分) (线性可分)

注: 若原始空间有限维, 属性有限, 则一定  
存在一高维特征空间使样本可分

$\phi(x)$  为  $x$  映射后  $i$  特征向量

$$f(x) = w^T \phi(x) + b \quad (w, b)$$

$$\min \frac{1}{2} \|w\|^2$$

$$s.t. \quad y_i (w^T \phi(x_i) + b) \geq 1$$

对偶问题:

$$\max \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j (\phi(x_i)^T \cdot \phi(x_j))$$

$$s.t. \quad \sum_{i=1}^m \alpha_i y_i = 0$$

$$\alpha_i \geq 0 \quad i=1, 2, \dots, m$$

计算  $\phi(x_i)^T \cdot \phi(x_j)$ , 映射到特征空间后内积

$\left\{ \begin{array}{l} \text{维数很高} \\ \text{不易计算} \end{array} \right\} \rightarrow \text{直接算 } \phi(x_i)^T \cdot \phi(x_j) \quad \otimes$

设  $k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$  } 核技巧  
 $= \phi(x_i)^T \phi(x_j)$

即  $x_i, x_j$  在特征空间内积 等于在原始空间

通过函数  $k(\cdot, \cdot)$  计算

$$\max \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j k(x_i, x_j)$$

$$s.t. \quad \sum_{i=1}^m \alpha_i y_i = 0$$

$$\alpha_i \geq 0$$

$$\text{则 } f(x) = w^T \phi(x) + b$$

$$= \sum_{i=1}^m \alpha_i y_i (\phi(x_i)^T \cdot \phi(x)) + b$$

$$= \sum_{i=1}^m \alpha_i y_i \underbrace{k(x, x_i)}_{\text{支持向量距离}} + b$$

通过训练样本  
与核函数计算

核函数: 令  $X$  是输入空间,  $k(\cdot, \cdot)$  是定义在  $X \times X$  上  
对称函数, 则  $k$  是核函数当且仅当  $\forall D = \{x_1, \dots, x_n\}$   
核矩阵  $K$  总是半正定.

$$K = \begin{bmatrix} k(x_1, x_1) & \dots & k(x_1, x_n) \\ \vdots & & \vdots \\ k(x_m, x_1) & \dots & k(x_m, x_n) \end{bmatrix}$$

$\left\{ \begin{array}{l} \text{对称函数} \\ \text{核矩阵半正定} \end{array} \right\} \Rightarrow \text{核函数}$

常用:

① 线性核  $k(x_i, x_j) = x_i^T x_j$

② 多项式核  $k(x_i, x_j) = (x_i^T x_j)^d$

③ 高斯核  $k(x_i, x_j) = \exp(-\frac{\|x_i - x_j\|^2}{2\sigma^2})$

④ 拉普拉斯核  $k(x_i, x_j) = \exp(-\frac{\|x_i - x_j\|}{\sigma})$

⑤ sigmoid 核  $k(x_i, x_j) = \tanh(\beta x_i^T x_j + \theta)$

且  $\gamma_1, \gamma_2$  为核  $\Rightarrow \gamma_1, \gamma_2 > 0, \gamma_1 k_1 + \gamma_2 k_2$  为核

2)  $k_1, k_2$  为核  $\Rightarrow$

$$k_1 \otimes k_2(x, z) = k_1(x, z) k_2(x, z)$$

也是核

3)  $k_1$  是核  $\forall g(x)$

$$k(x, z) = g(x) k_1(x, z) g(z)$$

也是核

## 6.4 软间隔与正则化


硬间隔: 所有样本均满足  $y_i(w^T x_i + b) \geq 1$

软间隔: 允许某些样本不满足  
但数量应尽可能少

$$\min_{w, b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \log_2(y_i(w^T x_i + b) + 1) \quad C > 0$$

$$\log_2(z) = \begin{cases} 1 & \text{if } z \geq 0 \\ 0 & \text{otherwise} \end{cases} \quad \begin{matrix} \text{非凸非连续} \\ \text{0/1 损失} \end{matrix}$$

$$\begin{cases} \text{hinge 损失} & \max(0, 1-z) \\ \text{指数损失} & \exp(-z) \\ \text{对数损失} & \log(1 + \exp(-z)) \end{cases}$$



采用 hinge 损失  $L_{\text{hinge}} = \max(0, 1-z)$ ;

$$\min_{w, b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(w^T x_i + b))$$

引入松弛变量,  $\xi_i \geq 0$

$$\min_{w, b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i$$

$$\text{s.t. } y_i(w^T x_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0 \quad i = 1, 2, \dots, m$$

每个样本都有一个松弛变量

拉格朗日乘子法

$$L(w, b, \alpha, \xi, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i (1 - \xi_i - y_i(w^T x_i + b)) + \sum_{i=1}^m \mu_i \xi_i$$

$\alpha_i \geq 0, \mu_i \geq 0$  拉格朗日乘子

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^m \alpha_i y_i x_i = 0$$

$$\frac{\partial L}{\partial b} \Rightarrow \sum_{i=1}^m \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \xi} \Rightarrow C = \alpha_i + \mu_i$$

## 对偶问题

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$\text{s.t. } \sum_{i=1}^m \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C \quad i = 1, 2, \dots, m$$

差别在于对偶变量: 约束  $\begin{cases} 0 \leq \alpha_i \leq C \\ 0 \leq \alpha_i \end{cases}$

KKT 条件:

$$\begin{cases} \alpha_i > 0, \mu_i > 0 \\ y_i f(x_i) + 1 + \xi_i > 0 \\ \alpha_i (y_i f(x_i) + 1 + \xi_i) = 0 \\ \xi_i > 0, \mu_i \xi_i = 0 \end{cases}$$

$\alpha_i > 0$  或  $y_i f(x_i) + 1 + \xi_i = 0$   $\checkmark (x_i, y_i)$

若  $\alpha_i > 0$ , 则没有间隔

若  $\alpha_i \neq 0$  ①  $\alpha_i > 0, \alpha_i < C \Rightarrow \mu_i > 0 \Rightarrow \xi_i = 0$

则该样本在最大间隔边界上

②  $\alpha_i = C \Rightarrow \mu_i = 0 \begin{cases} \xi_i \leq 1 \text{ 间隔内部} \\ \xi_i > 1 \text{ 错误分类} \end{cases}$

0/1 损失替换成对数损失  $\Rightarrow$  逻辑回归

更一般: 第项: 描述间隔

第项: 误差

$$\min_f \underbrace{\Omega(f)}_{\text{结构风险}} + C \underbrace{\sum_{i=1}^m l(f(x_i), y_i)}_{\text{经验风险}}$$

结构风险

经验风险

模型与数据的拟合

## 6.5 支持向量回归 (SVR)

$$\min_{w, b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \epsilon_t(f(x_i) - y_i)$$

$$\epsilon_t = \begin{cases} 0 & \text{if } |z| \leq \epsilon \\ |z| - \epsilon & \text{if } |z| > \epsilon \end{cases}$$