

## 第二章 线性模型

$$f(x) = w_1 x_1 + w_2 x_2 + \dots + w_d x_d + b = w^T x + b$$

### 3.2 线性回归

离散属性：存在“序”关系  $\rightarrow$  连续值  
 身高  $\rightarrow \{0.0, 1.0\}$

无“序”关系  $\rightarrow$   $k$  维向量

$$(x_i, y_i): f(x_i) = w x_i + b \text{ 使 } f(x_i) \approx y_i$$

$$\text{均方误差: } (w^*, b^*) = \arg \min_{w, b} \sum_{i=1}^m (f(x_i) - y_i)^2 = \arg \min_{w, b} \sum_{i=1}^m (y_i - w x_i - b)^2$$

多元线性回归:  $f(x) = \hat{w}^T x$

$$\hat{w}^* = \arg \min (\hat{y} - X \hat{w})^T (\hat{y} - X \hat{w})$$

$$\frac{\partial E}{\partial \hat{w}} = 2 X^T (X \hat{w} - \hat{y})$$

广义线性模型:  $y = g^T(w^T x + b)$   $g(\cdot)$  单调可微  
 “联系函数”

对数线性模型:  $g(\cdot) = \ln(\cdot)$

采用加权最小二乘法或极大似然估计

### 3.3 对数几率回归

用于分类任务:

① 单位阶跃函数:  $y = \begin{cases} 0 & z < 0 \\ 0.5 & z = 0 \\ 1 & z > 0 \end{cases}$  不连续



② 对数几率函数 (logistic function)

一种 sigmoid 函数

$$y = \frac{1}{1 + e^{-(w^T x + b)}}$$

$$\Rightarrow \ln \frac{y}{1-y} = w^T x + b$$

$y \rightarrow$  正例 几率: 作为正例的相对可能性  
 $1-y \rightarrow$  反例

对数几率, 用线性回归逼近真实标记  
 正对数几率, 直接对分类可微性建模

$$p(y=1|x) = \frac{e^{w^T x + b}}{1 + e^{w^T x + b}}$$

$$p(y=0|x) = \frac{1}{1 + e^{w^T x + b}}$$

极大似然估计, 求  $w, b$  对数似然

给定  $\{(x_i, y_i)\}_{i=1}^m$

对数似然:

$$l(w, b) = \sum_{i=1}^m \ln p(y_i | x_i; w, b)$$

$$\text{原式: } l(w, b) = \sum_{i=1}^m \ln p(y_i | x_i; w, b)$$

$$\beta = (w, b) \quad \hat{x} = (x; 1) \Rightarrow w^T x + b = \beta^T \hat{x}$$

$$p_1(\hat{x}; \beta) = p(y=1 | \hat{x}; \beta)$$

$$p_0(\hat{x}; \beta) = p(y=0 | \hat{x}; \beta)$$

$$l(w, b) = \sum_{i=1}^m \ln p(y_i | x_i; w, b) \text{ 最大化}$$

$$= \sum_{i=1}^m \ln p(y_i | \hat{x}_i; \beta)$$

$$= \sum_{i=1}^m \ln [y_i p(y_i=1 | \hat{x}_i; \beta) + (1-y_i) p(y_i=0 | \hat{x}_i; \beta)]$$

$$= \sum_{i=1}^m \ln \left[ \frac{y_i e^{w^T x_i + b}}{1 + e^{w^T x_i + b}} + \frac{(1-y_i)}{1 + e^{w^T x_i + b}} \right]$$

$$= \sum_{i=1}^m \ln \left( \frac{y_i e^{w^T x_i + b} + (1-y_i)}{1 + e^{w^T x_i + b}} \right)$$

$$= \sum_{i=1}^m [\ln(y_i e^{w^T x_i + b} + (1-y_i)) - \ln(1 + e^{w^T x_i + b})]$$

$$= \sum_{i=1}^m (y_i (w^T x_i + b) - \ln(1 + e^{w^T x_i + b}))$$

统计学习 (李航):

$$l(w, b) = \sum_{i=1}^m \ln p(y=1 | \hat{x}_i; \beta) y_i \ln p(y=0 | \hat{x}_i; \beta) (1-y_i)$$

对数似然:

$$= \sum_{i=1}^m [y_i \ln p(y=1 | \hat{x}_i; \beta) + (1-y_i) \ln p(y=0 | \hat{x}_i; \beta)]$$

$$= \sum_{i=1}^m [y_i \ln \frac{e^{w^T \hat{x}_i}}{1 + e^{w^T \hat{x}_i}} + (1-y_i) \ln \frac{1}{1 + e^{w^T \hat{x}_i}}]$$

$$= \sum_{i=1}^m [y_i w^T \hat{x}_i - \ln(1 + e^{w^T \hat{x}_i})]$$

### 3.4 线性判别分析

找一条直线, 使训练集合中的两类点投影到该直线上时, 同类点尽可能近, 异类点尽可能远

$X_i$ :  $i \in \{0, 1\}$  类的集合

$\mu_i$ :  $i \in \{0, 1\}$  类的均值向量

$\Sigma_i$ :  $i \in \{0, 1\}$  类的协方差矩阵

投影到直线上:  $w^T \mu_0, w^T \mu_1$   
 $w^T \Sigma_0 w, w^T \Sigma_1 w$

同样例: 投影点协方差尽可能小

$$w^T \Sigma_0 w + w^T \Sigma_1 w \downarrow$$

异类远离

$$\|w^T \mu_0 - w^T \mu_1\|_2^2 \uparrow$$

$$\max J = \frac{\|w^T \mu_0 - w^T \mu_1\|_2^2}{w^T \Sigma_0 w + w^T \Sigma_1 w} \uparrow$$

$$= \frac{w^T (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T w}{w^T (\Sigma_0 + \Sigma_1) w}$$

类内散度:  $S_w = \Sigma_0 + \Sigma_1$

$$= \sum_{x \in X_0} (x - \mu_0)(x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1)(x - \mu_1)^T$$

类间散度:  $S_b = (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T$

$$J = \frac{w^T S_b w}{w^T S_w w}$$

$S_b$  与  $S_w$  广义瑞利商

$$\min J = -w^T S_b w$$

$$s.t., w^T S_w w = 1$$

拉格朗日乘子

$$\mathcal{L}(w, \lambda) = w^T S_b w + \lambda (w^T S_w w - 1)$$

$$\frac{\partial J}{\partial w} = -2S_b w + 2\lambda S_w w = 0 \Rightarrow S_b w = \lambda S_w w$$

?  $S_b w$  方向恒为  $\mu_0 - \mu_1$ , 不妨令

$$S_b w = \lambda (\mu_0 - \mu_1)$$

$$w = S_w^{-1} (\mu_0 - \mu_1)$$

### 3.5 多分类学习

拆:  $\begin{cases} \text{一对一} & OvO \\ \text{一对余} & OvR \\ \text{多对多} & MvM \end{cases}$

OvO: 两两两两成一个分类器  $\frac{N(N-1)}{2}$   
预测时投票: 存储预测用的大训练集

OvR: 某一类作为正例, 其余为负例,  $N$  个  
预测时只有 1 个规则排序, 置信度最大的最终类别, 训练大

MvM: 若干类为正, 若干类为负

用训练输出码 (ECC)

编码:  $N$  类  $M$  次划分,  $M$  个分类器

每次划分: 一部分为正, 一部分为负, 二分类

解码:  $M$  个分类器分别进行预测, 组合

成一个编码, 与每类编码进行比较

返回距离最小的

### 3.6 类别不平衡问题

$y = w^T x + b$  来预测

阈值为 0.5  $\Leftrightarrow \begin{cases} \frac{y}{1-y} > 1 \Rightarrow \text{正} \\ \frac{y}{1-y} < 1 \Rightarrow \text{负} \end{cases}$

分类器默认: 真实正负例可能性相同

真实几率

观测几率  $\frac{m^+}{m^-}$  假设是无偏采样, 真实分布与训练集一样

$$\text{令 } \frac{y}{1-y} = \frac{y}{1-y} \times \frac{m^-}{m^+} \text{ (再缩放) 即 } \frac{y}{1-y} > \frac{m^+}{m^-}$$

① 欠采样

② 过采样

③ 阈值移动: 照常训练, 预测后再缩放